



Univerzitet u Nišu
Elektronski Fakultet



Vision-Language Assistant korišćenjem Florence-2 modela

Mentor:
prof. dr Aleksandar Milosavljević

Student:
Filip Stamenković 2027

Niš, 2026.

Sadržaj

1. Uvod	3
2. Teorijska osnova i korišćene tehnologije	4
2.1 Vision-Language modeli	4
2.2 Florence-2 model	4
2.3 Korišćene tehnologije	6
3. Arhitektura i implementacija	7
3.1 Arhitektura sistema	7
3.2 Backend implementacija	8
3.3 Frontend implementacija	9
4. Rezultati i evaluacija	9
4.1 Image Captioning	10
4.2 Detailed Caption	10
4.3 OCR i OCR with Region	11
4.4 Object Detection	12
4.5 Dense Region Captioning	13
4.6 Open Vocabulary Detection	14
4.7 Referring Expression Segmentation	15
4.8 Sumarni prikaz rezultata	16
5. Zaključak	17
6. Literatura	18

1. Uvod

Računarski vid predstavlja jednu od najznačajnijih oblasti veštačke inteligencije, čiji je cilj razvoj sistema sposobnih za razumevanje i analizu vizuelnih informacija. Tradicionalni pristupi u ovoj oblasti uglavnom su bili zasnovani na razvoju posebnih modela za svaki pojedinačni zadatak, poput klasifikacije slika, detekcije objekata ili optičkog prepoznavanja teksta (OCR). Razvojem velikih foundation modela, kao i napretkom transformer arhitekture, omogućen je drugačiji pristup u kojem jedan model može izvršavati veliki broj različitih zadataka korišćenjem odgovarajućih tekstualnih promptova [1].

Florence-2 predstavlja savremeni vision-language foundation model razvijen od strane kompanije Microsoft, namenjen rešavanju širokog spektra zadataka iz oblasti računarskog vida korišćenjem jedinstvene arhitekture. Model omogućava izvršavanje zadataka kao što su generisanje opisa slike, detekcija objekata, optičko prepoznavanje teksta, odgovaranje na pitanja o sadržaju slike, segmentacija i brojni drugi zadaci, pri čemu nije potrebno razvijati poseban model za svaku funkcionalnost [1].

Cilj ovog projekta jeste razvoj web aplikacije koja demonstrira mogućnosti Florence-2 modela kroz intuitivan korisnički interfejs. Korisniku je omogućeno otpremanje proizvoljne slike, izbor željenog zadatka i prikaz rezultata inferencije modela. Implementirano rešenje zasnovano je na klijent-server arhitekturi, pri čemu je backend razvijen korišćenjem FastAPI framework-a i zadužen je za izvršavanje modela i obradu rezultata, dok je frontend realizovan u React okruženju i omogućava interakciju korisnika sa sistemom.

Pored implementacije aplikacije, cilj rada je i analiza mogućnosti Florence-2 modela kroz praktične primere, kao i prikaz njegovih prednosti i ograničenja prilikom rešavanja različitih zadataka računarskog vida.

2. Teorijska osnova i korišćene tehnologije

2.1 Vision-Language modeli

Vision-Language modeli predstavljaju klasu multimodalnih modela dubokog učenja koji omogućavaju zajedničku obradu vizuelnih i tekstualnih podataka. Za razliku od klasičnih modela računarskog vida, koji su namenjeni rešavanju jednog specifičnog zadatka, Vision-Language modeli povezuju informacije dobijene iz slike sa prirodnim jezikom i omogućavaju izvršavanje velikog broja različitih zadataka korišćenjem jedinstvene arhitekture.

Osnovna ideja ovih modela jeste prevođenje vizuelnog sadržaja u reprezentaciju koju je moguće povezati sa tekstualnim informacijama. Na taj način model može da razume sadržaj slike i izvršava zadatke poput generisanja opisa slike (Image Captioning), optičkog prepoznavanja teksta (OCR), detekcije objekata i segmentacije objekata. Umesto razvoja zasebnog modela za svaki od navedenih zadataka, isti model se može koristiti za različite namene promenom odgovarajućeg tekstualnog prompta.

Savremeni Vision-Language modeli zasnovani su na transformer arhitekturi, koja omogućava modelovanje odnosa između različitih delova slike i teksta pomoću mehanizma pažnje (Attention Mechanism). Veliki skupovi podataka korišćeni tokom procesa treniranja omogućavaju modelima da nauče zajedničku reprezentaciju vizuelnih i tekstualnih informacija, čime se postiže visok nivo generalizacije i mogućnost rešavanja velikog broja zadataka bez dodatnog treniranja.

Zahvaljujući ovakvom pristupu, Vision-Language modeli predstavljaju značajan korak napred u odnosu na tradicionalne metode računarskog vida i danas se smatraju jednom od najznačajnijih oblasti razvoja veštačke inteligencije.


2.2 Florence-2 model

Florence-2 je vision-language foundation model razvijen od strane kompanije Microsoft sa ciljem objedinjavanja velikog broja zadataka računarskog vida u okviru jednog modela [1]. Za razliku od tradicionalnih pristupa, kod kojih je za svaki zadatak neophodno koristiti poseban model, Florence-2 omogućava izvršavanje različitih zadataka korišćenjem jednog modela i odgovarajućeg tekstualnog prompta. Na taj način isti model može biti iskorišćen za generisanje opisa slike, detekciju objekata, optičko prepoznavanje teksta, segmentaciju objekata, odgovaranje na pitanja o sadržaju slike i mnoge druge zadatke.

Model je treniran na velikom multimodalnom skupu podataka FLD-5B (Florence-2 Large-scale Dataset), koji sadrži više milijardi anotacija različitih tipova [1]. Skup podataka obuhvata slike povezane sa tekstualnim opisima, oznakama objekata, segmentacionim maskama, OCR anotacijama i drugim informacijama koje omogućavaju modelu da nauči zajedničku

reprezentaciju vizuelnih i tekstualnih podataka. Zahvaljujući ovakvom načinu treniranja, Florence-2 poseduje sposobnost generalizacije na veliki broj zadataka bez potrebe za dodatnim treniranjem.

Arhitektura Florence-2 modela zasnovana je na encoder-decoder transformer strukturi [1]. Vizuelni enkoder zadužen je za ekstrakciju karakteristika iz ulazne slike, dok dekoder generiše tekstualni izlaz ili strukturisane rezultate u zavisnosti od izabranog zadatka. Umesto korišćenja posebnih izlaznih grana za različite zadatke, Florence-2 koristi jedinstven mehanizam zasnovan na tekstualnim promptovima. Odabrani prompt određuje koji zadatak će model izvršiti, dok se sama inferencija obavlja korišćenjem iste arhitekture [1].



Slika 1: Arhitektura Florence-2 modela [1].

U okviru ovog projekta korišćen je model microsoft/Florence-2-base, dostupan putem Hugging Face platforme. Model je integrisan korišćenjem biblioteke Transformers, koja omogućava jednostavno učitavanje prethodno istreniranih modela i izvršavanje inferencije. Nakon generisanja rezultata, izlaz modela se parsira u odgovarajući format, a zatim se, u zavisnosti od tipa zadatka, prikazuje kao tekstualni odgovor ili se dodatno obrađuje radi iscrtavanja anotacija na ulaznoj slici.

Jedna od najvećih prednosti Florence-2 modela jeste podrška za veliki broj različitih zadataka korišćenjem jednostavnog sistema promptova. U ovom projektu implementirane su sledeće funkcionalnosti:

- Caption

- Detailed Caption
- More Detailed Caption
- OCR (Optical Character Recognition)
- OCR with Region
- Object Detection
- Dense Region Caption
- Region Proposal
- Caption to Phrase Grounding
- Referring Expression Segmentation
- Open Vocabulary Detection
- Region to Segmentation
- Region to Category
- Region to Description
- Region to OCR

Za svaki od navedenih zadataka dovoljno je proslediti odgovarajući prompt zajedno sa ulaznom slikom, nakon čega model generiše rezultat bez potrebe za promenom arhitekture ili ponovnim treniranjem.

2.3 Korišćene tehnologije

Za realizaciju projekta korišćen je skup savremenih tehnologija koje omogućavaju razvoj aplikacija zasnovanih na modelima dubokog učenja. Izabrane tehnologije obuhvataju biblioteke za izvršavanje modela, razvoj serverske i klijentske strane aplikacije, kao i obradu i prikaz rezultata.

Python je korišćen kao primarni programski jezik za implementaciju serverskog dela aplikacije. Zahvaljujući velikom broju biblioteka iz oblasti mašinskog učenja i obrade slika, predstavlja standard u razvoju sistema zasnovanih na veštačkoj inteligenciji.

PyTorch predstavlja biblioteku za duboko učenje koja omogućava izvršavanje prethodno istreniranih neuronskih mreža [2]. U okviru ovog projekta korišćen je za učitavanje i izvršavanje Florence-2 modela tokom procesa inferencije.

Biblioteka **Transformers (Hugging Face Transformers)** omogućava jednostavno korišćenje velikog broja prethodno istreniranih modela. U projektu je korišćena za učitavanje Florence-2 modela i odgovarajućeg procesora, pripremu ulaznih podataka i obradu rezultata koje model generiše [3].

FastAPI framework korišćen je za razvoj REST API-ja koji predstavlja komunikacioni sloj između korisničkog interfejsa i Florence-2 modela. Backend prihvata slike i korisničke zahteve, izvršava inferenciju modela i vraća rezultate u odgovarajućem formatu [4].

React (Next.js) je korišćen za razvoj korisničkog interfejsa aplikacije. Omogućava jednostavno otpremanje slika, izbor željenog zadatka i prikaz rezultata koje generiše Florence-2 model [5][8].

OpenCV biblioteka korišćena je za obradu slika i vizuelizaciju rezultata modela. Pomoću nje se iscrtavaju granični okviri, poligoni i tekstualne oznake koje Florence-2 generiše za zadatke poput detekcije objekata, OCR-a i segmentacije [6].

Pillow biblioteka korišćena je za učitavanje i osnovnu obradu slika pre njihovog prosleđivanja modelu [7].


3. Arhitektura i implementacija

3.1 Arhitektura sistema

Razvijena aplikacija zasnovana je na klijent-server arhitekturi. Sistem se sastoji od korisničkog interfejsa razvijenog u React (Next.js) okruženju, serverske aplikacije implementirane korišćenjem FastAPI framework-a i Florence-2 modela koji izvršava inferenciju nad prosleđenim slikama. Komunikacija između klijenta i servera ostvaruje se putem REST API-ja, pri čemu se slike i dodatni parametri šalju korišćenjem HTTP POST zahteva.

Korisnik putem web interfejsa otprema željenu sliku i bira zadatak koji želi da izvrši. Nakon prijema zahteva, backend čuva sliku, priprema ulazne podatke za Florence-2 model i pokreće inferenciju. Rezultat koji model generiše zatim se obrađuje u zavisnosti od izabranog zadatka. Za zadatke koji proizvode tekstualni izlaz rezultat se direktno vraća korisniku, dok se za zadatke poput detekcije objekata, OCR-a i segmentacije dodatno generiše anotirana verzija slike korišćenjem OpenCV biblioteke.

Na kraju procesa backend formira odgovor koji sadrži tekstualni rezultat, putanju do anotirane slike (ukoliko postoji) i druge informacije neophodne za prikaz rezultata u korisničkom interfejsu.



Slika 2: Arhitektura razvijene aplikacije.

3.2 Backend implementacija

Serverski deo aplikacije razvijen je korišćenjem FastAPI framework-a i predstavlja centralnu komponentu sistema. Njegova uloga je prihvatanje zahteva od korisničkog interfejsa, izvršavanje inferencije Florence-2 modela, obrada rezultata i slanje odgovora nazad klijentu.

Prilikom pokretanja aplikacije inicijalizuje se instanca klase Florence2Model, koja učitava odgovarajući procesor i prethodno istrenirani Florence-2 model iz Hugging Face repozitorijuma. Na ovaj način model se učitava samo jednom tokom rada aplikacije, čime se izbegava ponovno učitavanje pri svakom korisničkom zahtevu i značajno smanjuje vreme obrade.

Nakon prijema HTTP zahteva, backend prihvata otpremljenu sliku i informacije o željenom zadatku. Slika se privremeno čuva na serveru, nakon čega se učitava i prosleđuje Florence-2 modelu zajedno sa odgovarajućim promptom. Prompt određuje koji zadatak će model izvršiti, dok ostatak procesa inferencije ostaje nepromenjen bez obzira na izabranu funkcionalnost.

Nakon završetka inferencije, generisani rezultat se parsira korišćenjem funkcionalnosti koje obezbeđuje Florence-2 procesor. U zavisnosti od tipa zadatka, rezultat može predstavljati tekstualni opis slike, odgovor na postavljeno pitanje ili strukturisane podatke koji sadrže koordinate objekata, regione teksta ili poligone za segmentaciju.

Za zadatke koji proizvode prostorne informacije, poput detekcije objekata, OCR-a i segmentacije, backend dodatno obrađuje rezultate korišćenjem OpenCV biblioteke. Na osnovu koordinata koje model generiše iscrtavaju se granični okviri, poligoni i tekstualne oznake, nakon čega se kreira anotirana verzija slike koja se zajedno sa tekstualnim rezultatima vraća korisniku.

3.3 Frontend implementacija

Klijentski deo aplikacije razvijen je korišćenjem React biblioteke i Next.js framework-a. Njegova osnovna uloga je da korisniku omogući jednostavno otpremanje slike, izbor zadatka koji Florence-2 model treba da izvrši i pregled dobijenih rezultata.

Korisnički interfejs sadrži komponentu za izbor slike sa lokalnog uređaja. Nakon izbora datoteke prikazuje se pregled slike, čime korisnik može proveriti da li je izabrao odgovarajući sadržaj pre slanja zahteva. Pored slike, korisnik bira jedan od podržanih zadataka, kao što su generisanje opisa, OCR, detekcija objekata ili segmentacija.

Za pojedine zadatke potrebno je uneti i dodatni tekstualni sadržaj. Na primer, kod Open Vocabulary Detection i Referring Expression Segmentation zadataka unosi se naziv ili opis objekta koji treba pronaći. Na osnovu izabranog zadatka interfejs dinamički prikazuje odgovarajuće polje za unos.

Nakon pokretanja obrade frontend formira multipart/form-data zahtev koji sadrži sliku, odabrani prompt i eventualni dodatni tekst korisnika. Zahtev se prosleđuje FastAPI backend-u putem HTTP POST metode.

Po prijemu odgovora, način prikaza zavisi od tipa izvršenog zadatka. Tekstualni rezultati, poput opisa slike, OCR sadržaja ili odgovora na pitanje, prikazuju se u posebnoj sekciji korisničkog interfejsa. Za zadatke koji uključuju prostorne anotacije prikazuje se obrađena slika sa iscrtanim graničnim okvirima, oznakama ili segmentacionim poligonima.

Komponente korisničkog interfejsa organizovane su tako da je moguće jednostavno dodavanje novih Florence-2 zadataka. Za svaki zadatak čuvaju se naziv, odgovarajući prompt i tip očekivanog rezultata, na osnovu čega frontend određuje koja polja treba prikazati i na koji način treba predstaviti odgovor servera.


4. Rezultati i evaluacija

Cilj ovog poglavlja je prikaz funkcionalnosti implementirane aplikacije kroz primere izvršavanja različitih zadataka koje podržava Florence-2 model. Za svaki zadatak prikazan je ulazni primer, rezultat koji model generiše i kratak komentar o kvalitetu dobijenog izlaza.

Svi eksperimenti izvršeni su korišćenjem modela microsoft/Florence-2-base, pri čemu se inferencija izvršava lokalno na računaru korisnika. Rezultati obuhvataju tekstualne izlaze, kao i vizuelne anotacije generisane na osnovu koordinata koje vraća model.

4.1 Image Captioning

Zadatak Image Captioning omogućava automatsko generisanje kratkog opisa sadržaja slike. Nakon prosleđivanja odgovarajućeg prompta, Florence-2 analizira vizuelni sadržaj i generiše prirodan tekst koji opisuje najvažnije elemente slike.




Slika 3: Rezultat Image Captioning upita.

Komentar:

Na testiranim primerima model uspešno identifikuje glavne objekte i njihove međusobne odnose. Generisani opisi su gramatički ispravni i predstavljaju sažet prikaz sadržaja slike.

4.2 Detailed Caption

Za razliku od osnovnog opisivanja slike, Detailed Caption generiše detaljniji tekst koji sadrži više informacija o objektima, njihovom rasporedu i okruženju.



Slika 4: Rezultat Detailed Caption upita.

Komentar:

Dobijeni rezultat sadrži znatno više informacija u odnosu na osnovni Caption zadatak, što omogućava preciznije razumevanje sadržaja slike.

4.3 OCR i OCR with Region

OCR omogućava prepoznavanje teksta koji se nalazi na slici, dok OCR with Region pored prepoznatog teksta vraća i koordinate regiona u kojima je tekst pronađen.




Slika 5: Rezultat OCR i OCR with Region upita.

Komentar:

Model uspešno prepoznaje tekst i određuje njegov položaj na slici. Vizuelne anotacije generisane korišćenjem OpenCV biblioteke omogućavaju jednostavnu proveru tačnosti rezultata.

4.4 Object Detection

Kod zadatka detekcije objekata Florence-2 identifikuje objekte na slici i vraća njihove granične okvire.




Slika 6: Rezultat Object Detection upita.

Komentar:

Rezultati pokazuju da model uspešno lokalizuje objekte i određuje njihove granice, pri čemu je većina objekata pravilno identifikovana.

4.5 Dense Region Captioning


Ovaj zadatak predstavlja kombinaciju lokalizacije i opisivanja objekata. Model generiše granične okvire za više regiona slike i za svaki region kreira odgovarajući tekstualni opis.



Slika 7: Rezultat Dense Region Captioning upita.

4.6 Open Vocabulary Detection

Za razliku od klasične detekcije objekata, kod ovog zadatka korisnik sam definiše objekat koji želi da pronađe na slici.




Slika 8: Rezultat Open Vocabulary Detection upita.

Komentar:

Model uspešno pronalazi objekte definisane tekstualnim upitom bez potrebe za unapred definisanim klasama.

4.7 Referring Expression Segmentation

Kod ovog zadatka korisnik tekstualno opisuje objekat koji želi da izdvoji, nakon čega Florence-2 generiše segmentacionu masku.



Slika 9: Rezultat Referring Expression Segmentation upita.

4.8 Sumarni prikaz rezultata

Na osnovu sprovedenih testiranja može se zaključiti da Florence-2 uspešno izvršava sve implementirane zadatke korišćenjem jedinstvene arhitekture i sistema promptova. Tekstualni zadaci, poput generisanja opisa slike i odgovaranja na pitanja, daju prirodne i razumljive rezultate, dok zadaci koji uključuju lokalizaciju objekata, OCR i segmentaciju proizvode precizne prostorne anotacije koje su dodatno vizualizovane u okviru razvijene aplikacije.

5. Zaključak

U okviru ovog projekta razvijena je web aplikacija za izvršavanje različitih zadataka računarskog vida korišćenjem Florence-2 vision-language modela. Aplikacija omogućava korisnicima da kroz jednostavan web interfejs otpreme sliku, odaberu željeni zadatak i pregledaju rezultate koje model generiše.

Backend sistema implementiran je korišćenjem FastAPI framework-a i zadužen je za komunikaciju sa Florence-2 modelom, obradu ulaznih podataka i postprocesiranje rezultata. Frontend aplikacija razvijena u React okruženju omogućava intuitivnu interakciju sa sistemom i prikaz tekstualnih i vizuelnih rezultata inferencije.

Tokom realizacije projekta implementirana je podrška za veći broj funkcionalnosti koje Florence-2 model nudi, uključujući generisanje opisa slike, detaljno opisivanje sadržaja, optičko prepoznavanje teksta, detekciju objekata, opisivanje regiona slike, segmentaciju objekata i odgovaranje na pitanja o sadržaju slike. Za zadatke koji zahtevaju prostorne anotacije razvijena je dodatna obrada rezultata korišćenjem OpenCV biblioteke, čime je omogućena vizuelizacija graničnih okvira, poligona i tekstualnih oznaka direktno na slici.

Rezultati testiranja pokazuju da Florence-2 uspešno izvršava veliki broj različitih zadataka korišćenjem jedinstvene arhitekture i sistema promptova, bez potrebe za korišćenjem posebnih modela za svaki pojedinačni zadatak. Implementirana aplikacija potvrđuje praktičnu primenljivost savremenih vision-language modela u razvoju inteligentnih sistema za analizu vizuelnih podataka.

Kao mogući pravci daljeg razvoja izdvajaju se optimizacija performansi korišćenjem GPU akceleracije, podrška za obradu video sadržaja, dodavanje novih vision-language modela radi poređenja performansi, kao i proširenje aplikacije naprednijim funkcionalnostima i dodatnim mogućnostima konfiguracije od strane korisnika.

6. Literatura

- [1] B. Xiao, H. Wu, W. Xu, X. Dai, H. Hu, Y. Lu, M. Zeng, C. Liu and L. Yuan, "Florence-2: Advancing a Unified Representation for a Variety of Vision Tasks," Dostupno: <https://arxiv.org/abs/2311.06242>
- [2] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," Advances in Neural Information Processing Systems (NeurIPS), vol. 32, 2019. Dostupno: <https://arxiv.org/abs/1912.01703>
- [3] T. Wolf et al., "HuggingFace's Transformers: State-of-the-art Natural Language Processing," Proceedings of EMNLP: System Demonstrations, 2020. Dostupno: <https://arxiv.org/abs/1910.03771>
- [4] FastAPI Documentation. Dostupno: <https://fastapi.tiangolo.com>
- [5] React Documentation. Dostupno: <https://react.dev>
- [6] OpenCV Documentation. Dostupno: <https://docs.opencv.org>
- [7] Pillow Documentation. Dostupno: <https://pillow.readthedocs.io>
- [8] Next.js Documentation. Dostupno: <https://nextjs.org/docs>